


# ANALYSE COMPORTEMENTALE CLIENTÈLE RETAIL



Présenté par : Salma Bouarada

Encadrante : Mme Fadoua Drira



# Sommaire

**01 Contexte & Objectifs**

**03 Pipeline de Prétraitement**

**05 Clustering K-Means**

**07 Classification – Random Forest**

**09 Bonnes Pratiques**


**02 Exploration des Données**

**04 Feature Engineering**

**06 Classification – Logistic Regression**

**08 Comparaison & Régression**

**10 Conclusion & Perspectives**



# Contexte & Objectifs



## Dataset Retail E-Commerce

**4 372**

Clients

**52**

Features initiales

**33.3%**

Taux de Churn



## 3 Problématiques Business

01

### Personnaliser le Marketing

Segmentation client pour des campagnes ciblées

02

### Réduire le Churn

Prédire et anticiper le départ des clients

03


### Optimiser le CA

Prédiction du revenu client (MonetaryTotal)



## Objectifs Pédagogiques

- ✓ Explorer la qualité des données réelles
- ✓ Nettoyer et encoder les features
- ✓ Réduire la dimension (ACP)
- ✓ Clustering, Classification, Régression
- ✓ Évaluer et interpréter les modèles
- ✓ Déployer une interface Flask



# Exploration – Qualité & Distributions



## Valeurs Manquantes

**Age** : 1 311 valeurs manquantes

**30%**  
du dataset

**AvgDaysBetween Purchases** : 79 valeurs manquantes

**1.8%**  
du dataset

**Solution** : Imputation par médiane pour les deux variables



## Valeurs Aberrantes

**SupportTickets** : Valeurs -1 et 999 (incohérentes)

**SatisfactionScore** : Valeurs -1, 0, 99 (hors échelle 1-5)

**Solution** : Remplacement par NaN puis imputation médiane



## Types de Données

**20**  
int64

**18**  
str


**14**  
float64

→ 52 features initiales de types variés



## Déséquilibre de Classes


Churners  
33.3%



Fidèles  
66.7%

Fidèles  
Churners

**Solution** : Stratify + class\_weight='balanced' + SMOTE



# Pipeline de Prétraitement – 13 Étapes

## 01 Imputation

Médiane Age (49.0) et AvgDaysBtw (1.1)

## 02 Parsing Dates

RegistrationDate → RegYear/Month/Day/  
Weekday

## 03 Feature Eng

IP\_IsPrivate créé, suppression  
CustomerID et  
NewsletterSubscribed

## 04 Capping Outliers

Méthode IQR sur 8 colonnes  
numériques

## 05 Nouvelles Features

MonetaryPerDay, AvgBasketValue,  
TenureRatio

## 06 Multicolinéarité

Suppression 7 features  
redondantes ( $|r| > 0.8$ )

## 07 Anti-Data Leakage

Suppression 2 proxies churn  
(SatisfactionScore,  
ZeroPriceCount)

## 08 Encodage

39 → 94 colonnes (One-Hot,  
Ordinal, Target Encoding)

## 09 Split 80/20

Stratifié : Train 3 497 | Test  
875 (33.3% churn)

## 10 StandardScaler

Fit sur train uniquement,  
sauvegarde scaler.pkl

## 11 SMOTE


Sur-échantillonnage  
train : 2 334 → 4 668  
(50/50)

## 12 ACP

62 composantes = 95%  
variance, sauvegarde  
pca.pkl

## 13 Sauvegarde

Tous les fichiers sauvegardés  
dans data/train\_test/ et data/  
processed/



# Feature Engineering & ACP

## 3 Nouvelles Features Métier

### 01 MonetaryPerDay

**Formule** :  $\text{MonetaryTotal} / (\text{Recency} + 1)$

Dépense quotidienne récente. Faible = client inactif → churn probable.

### 02 AvgBasketValue

**Formule** :  $\text{MonetaryTotal} / \text{Frequency}$

Valeur moyenne d'un panier. Capture le comportement par transaction.

### 03 TenureRatio

**Formule** :  $\text{Recency} / (\text{CustomerTenureDays} + 1)$

Proche de 1 = inactif longtemps vs ancienneté  
→ signal churn très fort.


## Suppressions pour Qualité

### Multicolinéarité (7)

MonetaryAvg, TotalTransactions,  
UniqueInvoices...

### Proxies Churn (2)

SatisfactionScore, ZeroPriceCount



# Feature Engineering & ACP



## Analyse en Composantes Principales

**93**


Features initiales

**62**


Composantes ACP

**95%**

Variance conservée




**Résultat** : Réduction de 33% du nombre de features tout en conservant 95% de l'information. Accélération du clustering et réduction du bruit.



# Clustering K-Means – Segmentation Client



## Résultats du Clustering (k=4)



## Interprétation des Profils

### Cluster 0 – Actifs Récents

Récence faible (-0.53), achats récents

### Cluster 1 – Atypiques

Très petite taille, comportements uniques

### Cluster 2 – Standards

Majorité, comportement moyen

### Cluster 3 – Dormants

Récence élevée (0.59), inactifs

# Clustering K-Means – Segmentation Client





## Distribution des Clusters

|             |   |                |
|-------------|---|----------------|
| • Cluster 0 | → | 296<br>6.3%    |
| • Cluster 1 | → | 12<br>0.3%     |
| • Cluster 2 | → | 3 264<br>69.9% |
| • Cluster 3 | → | 1 096<br>23.5% |



## Profils Moyens par Cluster





# Classification – Logistic Regression



## Meilleurs Hyperparamètres

- C (Régularisation) : **1**
- Penalty : **12**
- Solver : **lbfgs**
- Class Weight : **balanced**

➔ Meilleur F1 (CV) : **0.9896**



## Équilibre Train / Test

**0.9946**  
Train Score

**0.9874**  
Test Score

**0.0072**  
Différence



Excellent équilibre, pas de surapprentissage




## Performances sur Test Set

**0.9874**  
Accuracy

**0.9895**  
Precision

**0.9809**  
F1-Score

**0.9991**  
AUC-ROC



# Classification – Random Forest

## Meilleurs Hyperparamètres

- N\_Estimators : **200**
- Max Depth : **10**
- Min Samples Split : **10**
- Min Samples Leaf : **2**

➔ Meilleur F1 (CV) : **0.9996**

## Attention Data Leakage

- Score parfait détecté :

Train Score  
**1.0000**

Test Score  
**0.9977**

 Différence : 0.0023 — Excellent équilibre



## Performances sur Test Set

**0.9977**

Accuracy

**1.0000**


Precision

**0.9966**

F1-Score

**1.0000**

AUC-ROC




# Comparaison des Modèles & Régression



## Comparaison Classification

Logistic Regression Random Forest



## Meilleur Modèle Sélectionné

- Random Forest

0.9966

F1-Score

1.0000

AUC-ROC

→ Sauvegardé sous models/best\_model.pkl



## Régression — RF-Regressor

- Objectif : Prédire MonetaryTotal
- GridSearchCV : 4 candidats, 5 folds (20 fits)


0.0569  
MAE

0.0212  
MSE

0.1456  
RMSE

0.9753  
R<sup>2</sup>

| Métrique  | Logistic Reg. | Random Forest |
|-----------|---------------|---------------|
| Accuracy  | 0.9874        | 0.9977        |
| Precision | 0.9895        | 1.0000        |
| Recall    | 0.9725        | 0.9931        |
| F1-Score  | 0.9809        | 0.9966        |
| AUC-ROC   | 0.9991        | 1.0000        |



# Matrices de Confusion – Comparaison des Modèles

## Régression Logistique

Prédit: Churner

**VP**  
**334**

Vrais Positifs

Prédit: Churner

**FN**  
**3**

Faux Négatifs

**FP**  
**2**

Faux Positifs

**VN**  
**549**

Vrais Négatifs

## Random Forest ★

Prédit: Churner

**VP**  
**336**

Vrais Positifs

Prédit: Churner

**FN**  
**0**

Faux Négatifs

**FP**  
**0**

Faux Positifs

**VN**  
**552**


Vrais Négatifs

VP — Vrais Positifs : churner prédit correctement

VN — Vrais Négatifs : fidèle prédit correctement

FP — Faux Positifs : fidèle classé churner

FN — Faux Négatifs : churner manqué (coût élevé !)



# Bonnes Pratiques ML



## Bonnes Pratiques Appliquées



### StandardScaler sur train uniquement

Jamais fit sur le test set pour éviter le data leakage



### Split stratifié 80/20

Proportion churn identique : 33.3% dans train et test



### SMOTE sur train uniquement

Sur-échantillonnage après split pour préserver l'intégrité du test



### Suppression proxies churn

SatisfactionScore et ZeroPriceCount supprimés pour éviter le leakage



### AUC-ROC métrique privilégiée

Robuste au déséquilibre de classes et indépendante du seuil



## Architecture Flask

- **GET /**

Page formulaire HTML




- **POST /predict**

API REST → JSON avec résultats



- **GET /health**

Statut des modèles



# Conclusion & Perspectives



## Résultats Clés



### Qualité = 60% du Travail

Nettoyage, imputation, formats mixtes, outliers



### Rigueur Méthodologique

No leakage, stratify, class\_weight, SMOTE post-split



### Production-Ready

Modules séparés, Flask déployé, artefacts sauvegardés



## Enseignements



L'importance cruciale du prétraitement dans tout pipeline ML



La vigilance face au data leakage et aux scores suspects



L'équilibre entre performance et interprétabilité



## Perspectives d'Amélioration

- **Optuna pour Hyperparamètres**


Optimisation bayésienne plus efficace que GridSearch


- **Migration vers FastAPI**

API plus performante et moderne que Flask

- **Dashboard Streamlit**

Interface interactive pour visualiser les prédictions





# Prédiction de Churn Client

Interface de machine learning pour prédire le risque de désabonnement des clients retail et analyser les facteurs clés de fidélisation.

[▶ NOUVELLE PRÉDICTION](#)

99.8%

Accuracy



100.0%

Precision



99.3%

Recall



100.0%

AUC-ROC



## Prédiction Individuelle

Analysez le risque de churn pour un client spécifique en rentrant ses caractéristiques.

[Commencer](#)

## Prédiction par Lot


Importez un fichier CSV pour analyser plusieurs clients simultanément.

[Importer CSV](#)

## Tableau de Bord

Visualisez les statistiques, l'importance des features et les tendances.

[Voir Dashboard](#)



**MERCI POUR**  
**VOTRE ATTENTION !**